Csdldpt báo cáo - không có

Xử lý dữ liệu đa phương tiện (Học viện Công nghệ Bưu chính Viễn thông)



messages.pdf_cover_qr_code_label

messages.downloaded_by
messages.studocu_not_sponsored_or_endorsed_by_college

Đề bài : Xây dựng hệ CSDL lưu trữ và tìm kiếm nội dung file âm thanh.

1.Hãy xây dựng/sưu tầm một bộ dữ liệu gồm ít nhất 500 files âm thanh về các bài diễn thuyết, hoặc bài giảng, hoặc các lời kể chuyện có nội dung nhất định. Các files có độ dài phù hợp để chứa được nội dung về một vấn đề nào đó, mỗi file có nội dung về một chủ đề, do một người nói / diễn thuyết (SV tùy chọn định dạng file âm thanh).

2.Hãy xây dựng các thuộc tính để nhận diện nội dung của các file âm thanh và nhận diện giọng người nói có trong các file âm thanh từ bộ dữ liệu đã thu thập. Trình bày cụ thể về lý do dựa chọn và giá trị thông tin của các thuộc tính này. Trình bày về nguyên lý trích rút các đặc trưng của âm thanh về nội dung và các đặc trưng về giọng nói phù hợp với bài toán này.

3.Xây dựng hệ thống tìm kiếm file âm thanh với đầu vào là một file âm thanh mới do một người nói về một nội dung đã có và chưa có trong dữ liệu, đầu ra gồm 2 phần, một phần là 3 files âm thanh giống nhất về nội dung chứa trong file âm thanh đầu vào, và một phần là 3 files âm thanh có giọng nói giống nhất với giọng nói trong file đầu vào, các file kết quả xếp thứ tự giảm dần về độ tương đồng với file âm thanh đầu vào.

a.Trình bày sơ đồ khối của hệ thống và quy trình thực hiện yêu cầu của đề bài.

b.Trình bày quá trình trích rút, lưu trữ dưới dạng CSDL cho các thuộc tính đã sử dụng, và cách sử dụng các thuộc tính để tìm kiếm file âm thanh trong hệ thống. Trình bày các kết quả trung gian của quá trình tìm kiếm âm thanh nói trên.

4.Demo hệ thống và đánh giá kết quả đã đạt được.

I. MỞ ĐẦU

1.1 Bối cảnh

Sự bùng nổ của nội dung đa phương tiện, đặc biệt là âm thanh, đã tạo ra một nhu cầu cấp thiết về các công cụ tìm kiếm và phân tích thông minh. Việc tìm kiếm thủ công qua hàng giờ ghi âm là không khả thi và kém hiệu quả. Hệ thống tìm kiếm nội dung âm thanh dựa trên ngữ nghĩa và giọng nói mang lại nhiều ý nghĩa và tiềm năng ứng dụng to lớn:

- **Trong giáo dục:** Sinh viên và giảng viên có thể dễ dàng tìm kiếm các bài giảng, buổi nói chuyện theo chủ đề hoặc nội dung cụ thể.
- **Trong doanh nghiệp:** Các cuộc họp, hội thảo, cuộc gọi với khách hàng được ghi âm có thể được phân tích để trích xuất thông tin quan trọng.
- **Trong truyền thông:** Nhà báo có thể nhanh chóng tìm kiếm các đoạn phỏng vấn, bản tin lưu trữ theo nội dung cần thiết.
- **Cho người dùng cá nhân:** Giúp quản lý và tìm lại thông tin trong các bản ghi âm cá nhân, podcast yêu thích một cách dễ dàng

1.2 Mục tiêu cụ thể của đề tài

studeersnel
messages.pdf_cover_qr_code_label
messages.downloaded_by

Dự án hướng tới xây dựng một hệ thống tìm kiếm đa phương thức (Multi-modal Retrieval) toàn diện với các mục tiêu kỹ thuật trọng tâm sau:

- **Xây dựng Dataset quy mô: Thu thập và chuẩn hóa bộ dữ liệu âm thanh gồm ít nhất 500 files đa dạng về chủ đề (bài giảng, diễn thuyết, podcast) để đảm bảo tính khách quan và khả năng đánh giá hệ thống.**
- **Chuyển đổi ngôn ngữ thô (Speech-to-Text): Tự động và chính xác chuyển đổi nội dung từ dạng sóng âm sang văn bản (transcript) bằng mô hình ASR tiên tiến nhất.**
- **Số hóa đặc trưng nội dung: Biểu diễn ý nghĩa ngữ nghĩa của âm thanh dưới dạng các vector embedding cao chiều, cho phép máy tính "hiểu" được nội dung thay vì chỉ so khớp từ khóa đơn thuần.**
- **Trích xuất bản sắc giọng nói (Speaker Verification): Xây dựng các thuật toán nhận diện đặc trưng sinh học của người nói (âm sắc, cao độ) để phân biệt các cá nhân khác nhau.**
- **Tìm kiếm Hybrid hiệu quả: Thiết kế cơ chế truy vấn trả về đồng thời 3 file tương đồng về nội dung và 3 file tương đồng về giọng nói, sắp xếp theo độ tương đồng giảm dần.**
- **Lưu trữ quản lý chuyên nghiệp: Tổ chức cơ sở dữ liệu kết hợp giữa SQL (cho metadata) và Vector Index (cho đặc trưng nhúng) để tối ưu hóa tốc độ truy xuất.**

1.3 Công nghệ chính được sử dụng

Hệ thống tích hợp các công nghệ AI và xử lý tín hiệu hiện đại nhất hiện nay:

- **Whisper (OpenAI):** Mô hình nhận dạng giọng nói tự động (ASR) đa ngôn ngữ, sử dụng kiến trúc Transformer để chuyển đổi âm thanh thành văn bản với độ chính xác cao đối với tiếng Việt.
- **Sentence-BERT (S-BERT):** Sử dụng model vietnamese-bi-encoder để tạo ra các vector embedding ngữ nghĩa, giúp so sánh sự tương đồng giữa các đoạn văn bản trong không gian vector.
- **FAISS (Facebook AI Similarity Search):** Thư viện chuyên dụng để tìm kiếm lân cận gần nhất (k-NN) trên tập hợp hàng triệu vector với tốc độ mili giây.
- **YAKE! (Yet Another Keyword Extractor):** Thuật toán trích xuất từ khóa tự động không giám sát, dựa trên các đặc trưng thống kê của văn bản.
- **ECAPA-TDNN:** Mô hình Deep Learning tiên tiến (thường dùng trong SpeechBrain) chuyên biệt cho việc trích xuất **Speaker Embedding** nhằm nhận dạng danh tính người nói.
- **YIN Algorithm:** Thuật toán phân tích cao độ (Pitch) để xác định tần số cơ bản F0, hỗ trợ phân loại giọng nói.

studeersnel
messages.pdf_cover_qr_code_label
messages.downloaded_by

- **MFCC (Mel-frequency cepstral coefficients):** Kỹ thuật tiền xử lý tín hiệu âm thanh để trích xuất các đặc trưng âm sắc mô phỏng thính giác con người.
- **MySQL:** Hệ quản trị cơ sở dữ liệu quan hệ dùng để lưu trữ metadata có cấu trúc và liên kết dữ liệu.

Các thư viện cốt lõi:

- **Librosa (Python Library):** Đây là thư viện cốt lõi dùng để thực hiện kỹ thuật **MFCC** và thuật toán **YIN/pYIN** nhằm trích xuất đặc trưng âm sắc thô và cao độ.
- **SpeechBrain (All-in-one Speech Toolkit):** Duy cần nêu rõ đây là bộ công cụ giúp triển khai mô hình **ECAPA-TDNN** để trích xuất **Speaker Embedding**.
- **Sentence-Transformers:** Thư viện dùng để thực thi mô hình **S-BERT** (vietnamese-bi-encoder) nhằm tạo ra các **Semantic Vectors** cho nội dung văn bản.
- **OpenAI-Whisper:** Thư viện chính thức dùng cho quá trình **Speech-to-Text** để lấy bản transcript thô

công cụ xử lý âm thanh nền tảng (The Engine)

- **FFmpeg:** Đây là "động cơ" cực kỳ quan trọng để xử lý các định dạng file đầu vào (MP3, WAV, WebM). Nó đóng vai trò chuẩn hóa âm thanh về **16,000Hz** và **Mono** trước khi đưa vào các mô hình AI để đảm bảo tính nhất quán.
- **Pydub:** (Tùy chọn) Nếu Duy có dùng để cắt nhỏ file (chunking), nên đưa vào để giải thích quy trình tiền xử lý

Cơ sở dữ liệu và Kết nối

- **SQL Connector (như mysql-connector-python):** Để làm rõ cách mã nguồn Python giao tiếp với **MySQL** nhằm lưu trữ và truy vấn metadata.
- **L2 Normalization (Kỹ thuật chuẩn hóa):** Duy nên đưa kỹ thuật này vào danh sách công nghệ vì nó là "chìa khóa" toán học giúp tối ưu hóa việc tìm kiếm tương đồng trong **FAISS**.

II.Xây dựng dataset

Quá trình thu thập dữ liệu đầu vào là một bước khởi đầu quan trọng, ảnh hưởng trực tiếp đến chất lượng và khả năng hoạt động của toàn bộ hệ thống tìm kiếm nội dung âm thanh. Việc lựa chọn và chuẩn bị dữ liệu một cách cẩn thận sẽ đảm bảo rằng mô hình nhận dạng giọng nói và mô hình trích xuất đặc trưng ngữ nghĩa có thể hoạt động tối ưu, từ đó mang lại kết quả tìm kiếm chính xác và phù hợp cho người dùng

studeersnel
messages.pdf_cover_qr_code_label
messages.downloaded_by

- **2.1 Mô tả dữ liệu**

Để phục vụ cho việc xây dựng và thử nghiệm hệ thống, một tập dữ liệu âm thanh đa dạng đã được thu thập. Các đặc điểm chính của tập dữ liệu này như sau:
· **Số lượng file âm thanh:** Mục tiêu thu thập tối thiểu 500 file âm thanh để đảm bảo có đủ dữ liệu cho việc đánh giá các thành phần của hệ thống, từ quá trình trích xuất transcript đến xây dựng chỉ mục tìm kiếm.
· **Loại nội dung:** Dữ liệu tập trung vào các nội dung có cấu trúc lời nói tương đối rõ ràng và mang tính thông tin, bao gồm:
o Bài giảng: Các bài thuyết trình học thuật, bài giảng chuyên đề.
o Diễn thuyết: Các bài phát biểu, buổi nói chuyện trước công chúng.
o Kể chuyện/Podcast: Các nội dung kể chuyện, podcast có một người dẫn chính.
Sự đa dạng này giúp kiểm thử khả năng của hệ thống trên các loại hình nội dung khác nhau.
· **Ngôn ngữ:** Chủ yếu là **tiếng Việt**, nhằm mục tiêu xây dựng một hệ thống phục vụ tốt cho người dùng Việt Nam.
· **Định dạng file:** Các định dạng âm thanh phổ biến và chất lượng tốt như MP3 và WAV được ưu tiên sử dụng để đảm bảo tính tương thích và chất lượng âm thanh đầu vào cho mô hình ASR.
· **Nguồn dữ liệu:** Dữ liệu được thu thập từ các nguồn công khai và có sẵn như YouTube: Các kênh giáo dục, podcast, diễn thuyết. Việc sử dụng nguồn này đảm bảo tính hợp pháp và đa dạng của dữ liệu.

2.2 Tiêu chí chọn file

- **Một người nói (Single speaker):** Ưu tiên file có một người nói chính để module nhận diện giọng nói hoạt động tối ưu.
- **Chất lượng âm thanh:** Hạn chế tối đa tiếng ồn nền, tiếng vọng để tăng độ chính xác cho quá trình ASR và trích xuất MFCC.
- **Độ dài tối ưu (1 - 15 phút):** Tiêu chí này được thiết lập dựa trên giới hạn của tài nguyên tính toán và yêu cầu trích xuất đặc trưng. Các file dài hơn 1 phút đảm bảo cung cấp đủ thời lượng giọng nói thực (active speech) sau khi lọc khoảng lặng, giúp mô hình ECAPA-TDNN tổng hợp speaker_embedding_vector một cách ổn định. Ngược lại, việc giới hạn thời lượng dưới 15 phút nhằm ngăn chặn hiện tượng tràn bộ nhớ (Out of Memory - OOM) và kiểm soát rủi ro sinh ảo giác (hallucination) khi mô hình Whisper phải xử lý ngữ cảnh quá dài qua các cửa sổ trượt (sliding windows) 30 giây.

- **Chuẩn hóa tín hiệu (16,000Hz, Mono):** Thay vì sử dụng âm thanh thô với định dạng hỗn hợp, toàn bộ dữ liệu được hệ thống tự động tiền xử lý về định dạng 1 kênh (Mono) và tần số lấy mẫu 16kHz. Theo định lý Nyquist, mức 16kHz là mức tần số tối ưu để biểu diễn toàn bộ dải tần số giọng nói con người (tối đa 8000Hz). Việc đồng nhất định dạng này loại bỏ chi phí tính toán dư thừa từ âm thanh Stereo, đồng thời đáp ứng chính xác yêu cầu đầu vào mặc định của các kiến trúc mạng nơ-ron (Whisper, ECAPA-TDNN), giúp tránh hiện tượng sai lệch ma trận đặc trưng (feature mismatch).

studeersnel
messages.pdf_cover_qr_code_label
messages.downloaded_by

- **Chủ đề và người nói rõ ràng (Single speaker):** Mỗi file cần có tính mạch lạc, tập trung vào một chủ đề nhất định và ưu tiên chỉ có một người nói chính để các module nhận diện từ khóa và trích xuất danh tính giọng nói hoạt động với độ chính xác cao nhất.

III.Xây dựng bộ thuộc tính đặc trưng của âm thanh và nguyên lí trích rút

Sau khi hoàn tất quá trình thu thập và tiền xử lý dữ liệu âm thanh, bước tiếp theo và cũng là một trong những bước cốt lõi của hệ thống là trích rút các thuộc tính (đặc trưng) quan trọng từ mỗi file. Các thuộc tính này không chỉ đơn thuần là metadata mô tả file mà còn bao gồm các biểu diễn sâu hơn về mặt nội dung và ngữ nghĩa, làm cơ sở cho việc tìm kiếm và truy xuất thông tin hiệu quả.

3.1 Các thuộc tính trích rút từ file âm thanh

- **file_id (Định danh file):** Chuỗi ký tự duy nhất gán cho mỗi file âm thanh để làm khóa chính (Primary Key).
- **file_name_original (Tên file gốc):** Tên file ban đầu khi thu thập, dùng làm tham chiếu và hiển thị cho người dùng.
- **transcript_text (Nội dung văn bản):** Toàn bộ nội dung lời nói được chuyển đổi thành văn bản thô qua mô hình Whisper.
- **content_embedding_vector (Vector nội dung):** Vector số thực (thường 384 hoặc 768 chiều) đại diện cho ý nghĩa ngữ nghĩa của transcript.
- **extracted_keywords_automatic (Từ khóa tự động):** Danh sách các từ/cụm từ chính đại diện cho chủ đề của file.
- **speaker_embedding_vector (Vector giọng nói):** Vector mã hóa bản sắc giọng nói (âm sắc, đặc điểm sinh học) của người diễn thuyết.
- **pitch_feature (F0) (Cao độ):** Tần số cơ bản của giọng nói, dùng để nhận diện giọng trầm/bổng hoặc nam/nữ.
- **MFCCs (Hệ số Cepstral):** Tập hợp các hệ số đặc trưng cho hình dạng ống phát âm, là "vân tay" âm sắc để phân biệt các chất giọng khác nhau.

3.2 Lý do chọn các thuộc tính

Việc lựa chọn các thuộc tính trên được dựa trên mục tiêu xây dựng một hệ thống tìm kiếm nội dung âm thanh thông minh, linh hoạt và cung cấp trải nghiệm tốt cho người dùng. Dưới đây là lý giải chi tiết cho sự lựa chọn này:

3.2 Lý do chọn các thuộc tính

Việc lựa chọn các thuộc tính trên nhằm đảm bảo tính toàn diện cho bài toán tìm kiếm đa phương thức:

studeersnel

messages.pdf_cover_qr_code_label
messages.downloaded_by



- **Quản lý & Hiển thị (file_id, file_name_original):** Cần thiết để định danh duy nhất trong hệ thống và cung cấp thông tin trực quan cho người dùng.
- **Phân tích nội dung (transcript_text, keywords):** Giúp người dùng hiểu nhanh chủ đề mà không cần nghe toàn bộ file, đồng thời cung cấp dữ liệu đầu vào cho các bước phân tích sâu hơn.
- **Tìm kiếm ngữ nghĩa (content_embedding_vector):** Giải quyết nhược điểm của tìm kiếm từ khóa truyền thống bằng cách tìm kiếm dựa trên "ý nghĩa", cho phép trả về kết quả liên quan ngay cả khi không trùng khớp từ vựng hoàn toàn.

Nhận diện giọng nói (speaker_embedding_vector, MFCCs, pitch_feature): Đây là các thuộc tính sinh trắc học âm thanh cốt lõi, được lựa chọn theo nguyên tắc từ thô đến tinh:

- **MFCCs:** Được chọn để đại diện cho **đặc trưng âm sắc thô (raw/physical features)**. Chúng phản ánh cấu trúc vật lý của đường dẫn thanh âm (khoang miệng, vòm họng) của người diễn thuyết.
- **speaker_embedding_vector:** Đây là **đặc trưng sâu (deep features)** được tổng hợp từ chính chuỗi MFCCs thông qua mạng nơ-ron ECAPA-TDNN. Việc chọn thuộc tính này giúp hệ thống có khả năng "học" được các mẫu giọng nói phức tạp, tăng cường độ chính xác và khả năng tổng quát hóa khi tìm kiếm danh tính người nói giữa hàng trăm file khác nhau.
- **pitch_feature:** Đóng vai trò là thuộc tính bổ trợ, giúp tinh chỉnh độ chính xác và thu hẹp phạm vi tìm kiếm khi gặp các người nói có cùng tông giọng hoặc âm sắc tương đồng.
- .

3.3 Nguyên lý trích rút các đặc trưng của âm thanh

Quá trình trích rút đặc trưng là giai đoạn then chốt nhằm chuyển đổi tín hiệu âm thanh thô (waveform) thành các đại diện số học có cấu trúc. Hệ thống thực hiện trích rút song song hai nhóm đặc trưng: **Nội dung ngữ nghĩa** (hiểu nội dung) và **Danh tính giọng nói** (nhận diện người nói)

3.3.1 Khai thác Nội dung Ngôn ngữ và Ngữ nghĩa

1. Chuyển giọng nói thành văn bản (Speech-to-Text) – Khai thác nội dung ngôn ngữ thô

- **Công cụ sử dụng: Whisper (OpenAI)** – Một mô hình nhận dạng giọng nói tự động (ASR) mã nguồn mở tiên tiến.
- **Nguyên lý hoạt động:**
    - **Kiến trúc Transformer và Xử lý Tín hiệu:** Tín hiệu âm thanh đầu vào (waveform) trước tiên được chuyển đổi thành **log-Mel spectrogram** thông qua kỹ thuật Biến đổi Fourier Thời gian Ngắn (STFT). Thang đo Mel giúp mô phỏng cách tai người cảm nhận tần số, trong khi thang log giúp nén biên độ biên độ âm thanh.

studeersnel
messages.pdf_cover_qr_code_label
messages.downloaded_by

- **Encoder-Decoder:** Dữ liệu spectrogram được đưa qua các tầng **Encoder** của kiến trúc Transformer để tạo ra chuỗi biểu diễn tiềm ẩn. Sau đó, các tầng **Decoder** giải mã chuỗi này thành các token văn bản, hình thành bản transcript hoàn chỉnh (transcript_text).

- **Kết quả:** Đầu ra là văn bản transcript, làm nền tảng cho việc phân tích ngữ nghĩa và trích xuất từ khóa.

2. Biểu diễn nội dung văn bản dưới dạng vector ngữ nghĩa (Semantic Vector Representation)

- **Công cụ sử dụng: Sentence-BERT (S-BERT)** – Cụ thể là mô hình vietnamese-bi-encoder.

- **Nguyên lý hoạt động:**

  - **Kiến trúc Siamese/Triplet Network:** S-BERT sử dụng kiến trúc mạng Siamese để tinh chỉnh (fine-tuning) mô hình BERT, giúp kéo các câu có nghĩa tương đồng lại gần nhau và đẩy các câu không tương đồng ra xa nhau trong không gian vector.
  - **Tạo Vector Embedding:** Văn bản transcript được mã hóa thành một **dense vector** (content_embedding_vector) có số chiều cố định (ví dụ 768 chiều), nắm bắt ý nghĩa cốt lõi của nội dung.
  - **So sánh tương đồng:** Độ tương đồng giữa hai vector A và B được đo bằng **Cosine Similarity**:

$$CosineSimilarity(A,B) = \frac{A \cdot B}{\|A\|\|B\|} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2} \cdot \sqrt{\sum_{i=1}^{n} B_i^2}}$$

Kết quả: Mỗi file được đại diện bởi một vector nội dung, cho phép tìm kiếm theo ý nghĩa ngữ nghĩa thay vì chỉ so khớp từ khóa

3. Trích xuất từ khóa đặc trưng (Keyword Extraction)

- **Công cụ sử dụng:** YAKE! (Yet Another Keyword Extractor).

- **Nguyên lý hoạt động:**

  - **Thống kê không giám sát:** YAKE! phân tích các đặc trưng của từ và cụm từ (n-grams) dựa trên các yếu tố: Casing (viết hoa), Word Position (vị trí), Word Frequency (tần suất), và mối liên quan với ngữ cảnh.
  - **Tính điểm số S(kw):** Các ứng viên từ khóa có điểm số càng thấp thì mức độ quan trọng càng cao. Công thức tóm lược:

$$S(kw) = \frac{D_{norm} + (D_{rel} \cdot TF_{norm}) + (D_{rel} \cdot Pos_{norm})}{D_{rel} \cdot K_{spread}}$$

studeersnel

messages.pdf_cover_qr_code_label
messages.downloaded_by



Kết quả: Danh sách extracted_keywords_automatic hỗ trợ tóm tắt và lọc thông tin nhanh chóng

3.3.2 Khai thác Danh tính và Đặc trưng Giọng nói

4. Trích xuất hệ số Cepstral (MFCCs)

- **Công cụ sử dụng:** Thư viện **Librosa** (Python).
- **Nguyên lý hoạt động:** MFCC mô phỏng hệ thống thính giác con người bằng cách tách riêng nguồn âm (pitch) và bộ lọc thanh quản (formants). Quy trình gồm:
    - **Pre-emphasis:** Tăng cường năng lượng ở tần số cao để làm rõ các cộng hưởng âm:

$$x'[n] = x[n] - \alpha x[n-1] \quad (0.95 < \alpha < 0.99)$$

    - **Windowing:** Chia tín hiệu thành các khung trượt (25ms) và áp dụng cửa sổ Hamming để giảm rò rỉ phổ:

$$w[n] = 0.54 - 0.46\cos\left(\frac{2\pi n}{N-1}\right)$$

    - **DFT & Mel Filterbank:** Chuyển sang miền tần số bằng FFT và áp dụng các bộ lọc tam giác theo thang đo Mel. Công thức chuyển đổi Hz sang Mel:

$$m = 2595\log_{10}(1 + f/700)$$

    - **DCT:** Biến đổi Cosine rời rạc để thu được các hệ số độc lập.
- **Kết quả:** Hệ thống trích xuất 13 hệ số MFCC cùng các hệ số động $(\Delta \text{ và } \Delta^2)$ tạo thành vector 39 chiều (MFCCs)

5. Trích xuất Speaker Embedding (Danh tính giọng nói)

- **Nguyên lý kế thừa:** Thuộc tính này không được trích xuất trực tiếp từ sóng âm thô mà sử dụng đầu vào là chuỗi các hệ số **MFCCs** đã được tính toán ở bước 4.
- **Công cụ sử dụng:** Mô hình **ECAPA-TDNN**.
- **Quy trình:**
    - **Mạng nơ-ron TDNN:** Sử dụng kiến trúc Time Delay Neural Network để trích xuất các đặc trưng giọng nói sâu từ chuỗi MFCC.

studeersnel
messages.pdf_cover_qr_code_label
messages.downloaded_by

- **Global Context Pooling:** Tập hợp các đặc trưng ở cấp độ khung hình thành một vector cố định chiều (speaker_embedding_vector) mã hóa bản sắc riêng biệt của người nói.

- **Kết quả:** Một vector đại diện cho bản sắc giọng nói, cho phép phân biệt người nói ngay cả khi họ đọc cùng một nội dung.

6. Phân tích Cao độ (Pitch - F0)

- **Công cụ sử dụng:** Thuật toán **YIN** hoặc **pYIN**.

- **Nguyên lý hoạt động:** Xác định tần số cơ bản của giọng nói bằng cách tìm các chu kỳ lặp lại trong tín hiệu thông qua hàm hiệu số (Difference Function):

$$d_t(\tau) = \sum_{j=1}^{W} (x_j - x_{j+\tau})^2$$

- **Kết quả:** Thuộc tính pitch_feature giúp nhận diện giọng cao/thấp, hỗ trợ lọc và phân loại giọng nam/nữ hoặc các sắc thái biểu cảm.

3.3.3 Quản lý Metadata và Chuẩn hóa

7. file_id và 8. file_name_original

- **Nguyên lý:** Khi một file được thu thập, hệ thống gán một mã định danh duy nhất (file_id) và lưu lại tên gốc (file_name_original).

- **Vai trò:** file_id đóng vai trò khóa chính (Primary Key) trong MySQL để liên kết metadata với vector trong FAISS.

Chuẩn hóa và Lưu trữ Đặc trưng (Normalization)

- **L2 Normalization:** Trước khi thực hiện tìm kiếm k-NN trong FAISS, mọi vector (content_embedding và speaker_embedding) đều được chuẩn hóa về độ dài bằng 1:

$$\|v\|_2 = \sqrt{\sum_{i=1}^{n} v_i^2} \implies v' = \frac{v}{\|v\|_2}$$

- **Ý nghĩa:** Việc chuẩn hóa giúp tích vô hướng (Inner Product) của hai vector trở nên tương đương với Cosine Similarity, tối ưu hóa tốc độ và độ chính xác của chỉ mục **IndexFlatIP** trong FAISS.

studeersnel
messages.pdf_cover_qr_code_label
messages.downloaded_by

IV. Các thách thức kỹ thuật và Giải pháp tối ưu hóa

4.1. Khắc phục xung đột môi trường bằng kỹ thuật can thiệp mã nguồn (Monkey Patching)

- **Vấn đề:** Sự thay đổi liên tục của hệ sinh thái mã nguồn mở dẫn đến bất đồng bộ API. Cụ thể, thư viện SpeechBrain yêu cầu tham số use_auth_token khi tải mô hình ECAPA-TDNN, nhưng API phiên bản mới của HuggingFace đã khai tử tham số này. Hệ quả là hệ thống bị lỗi (Crash) toàn bộ dù logic lập trình chính xác. Thêm vào đó, nền tảng Windows thường thiếu backend giải mã âm thanh mặc định cho thư viện torchaudio.
- **Giải pháp:** Hệ thống đã áp dụng kỹ thuật can thiệp mã nguồn toàn cục (Global Monkey Patching) để tự động bắt lỗi và sửa đổi tham số mạng ngầm trước khi gửi request tải mô hình, đồng thời ép buộc hệ thống sử dụng backend soundfile.
- **Đánh giá:** Phương pháp này giúp hệ thống hoạt động trơn tru trên các phiên bản thư viện hiện đại nhất (đảm bảo hiệu năng và bảo mật) mà không cần phải thực hiện hạ cấp (downgrade) toàn bộ môi trường lập trình.

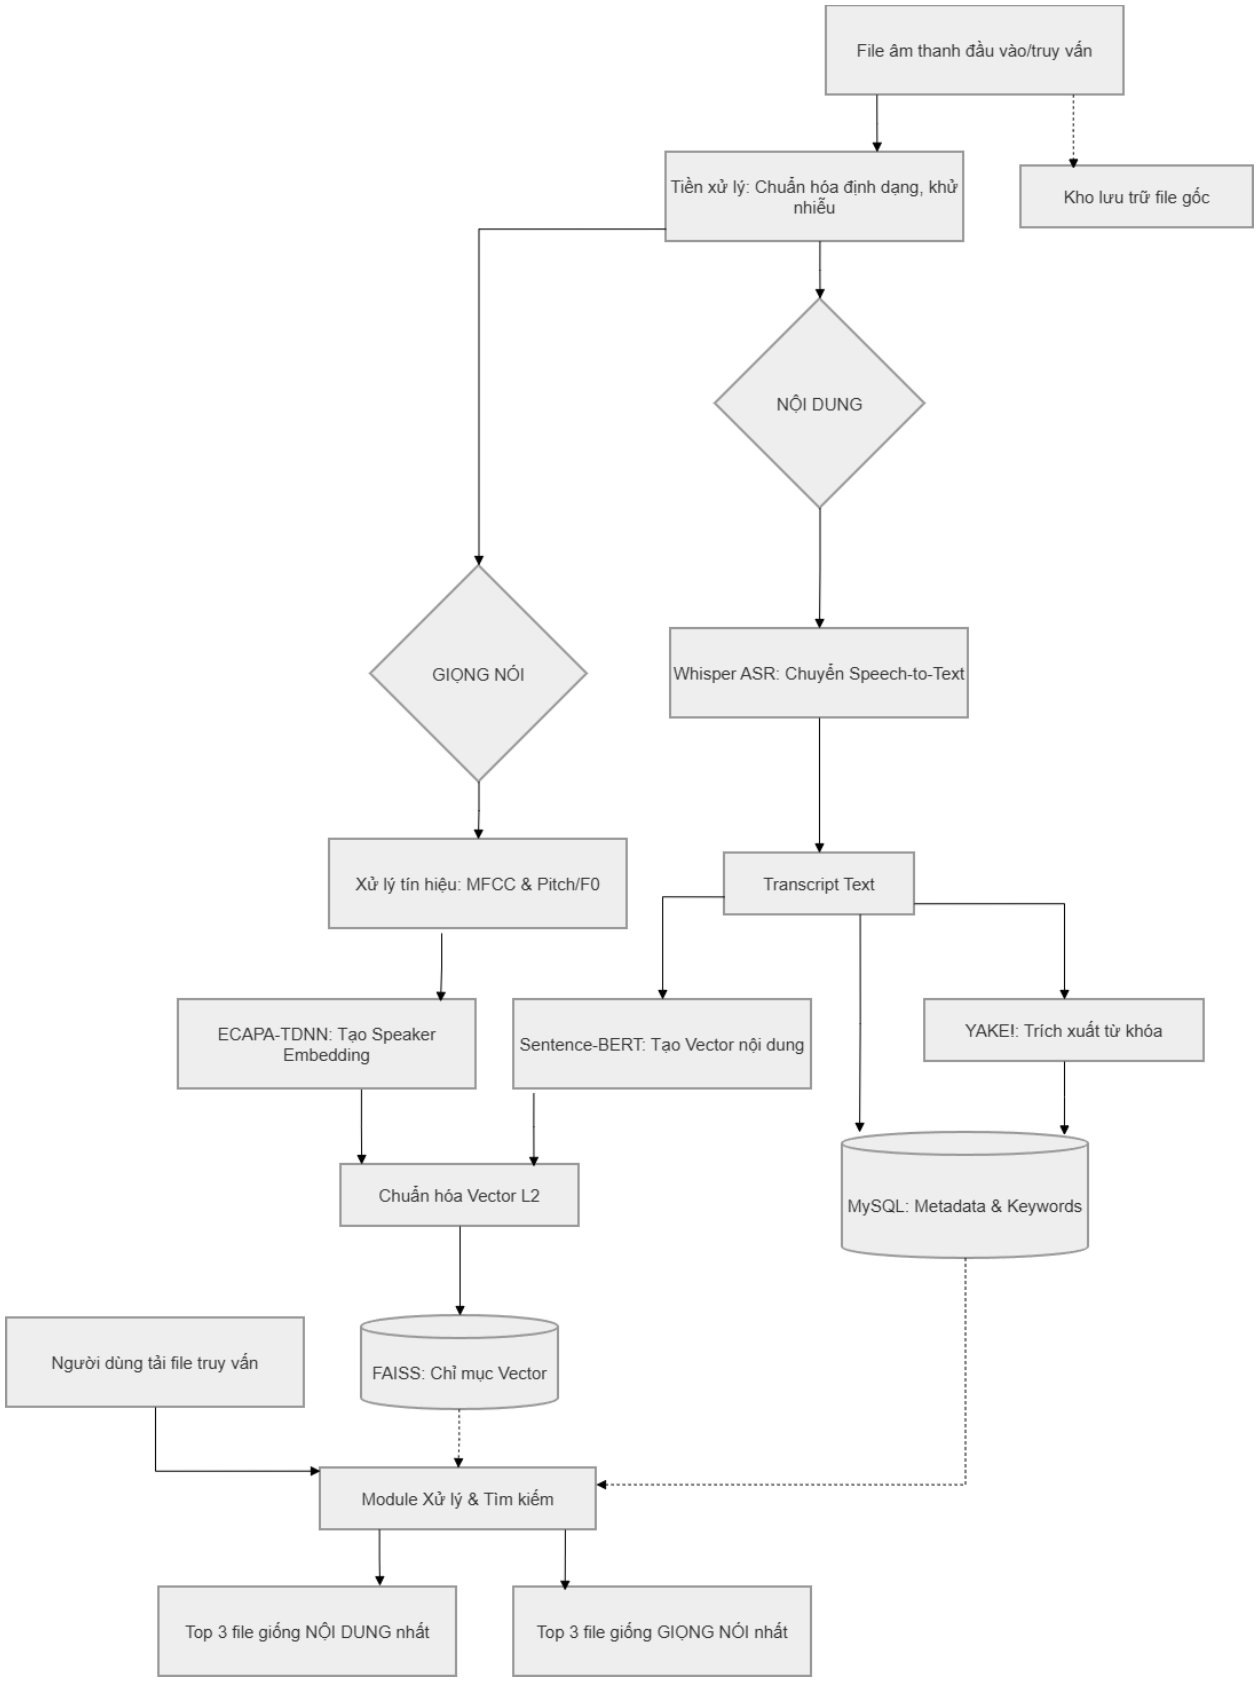
4.2. Xây dựng cơ chế chống lỗi (Fault Tolerance) cho Data Pipeline

- **Vấn đề:** Quá trình trích xuất đặc trưng AI cho hàng trăm file âm thanh là một tác vụ nặng, kéo dài nhiều giờ và tiêu thụ lượng lớn RAM/CPU. Nếu xảy ra sự cố đột xuất (treo máy, mất kết nối), toàn bộ dữ liệu vector đang lưu tạm trên bộ nhớ sẽ bị mất trắng.
- **Giải pháp:** Thiết kế cơ chế lưu trữ "gối đầu" (Checkpointing). Luồng xử lý (Data Pipeline) được lập trình để cứ sau mỗi chu kỳ 5 file, dữ liệu vector sẽ tự động được ghi nối (append) vào file CSDL gốc (audio_features_database.csv) và lập tức giải phóng bộ nhớ RAM.
- **Đánh giá:** Thiết kế này đảm bảo tính toàn vẹn dữ liệu. Khi có sự cố, hệ thống có khả năng tự động đối chiếu CSDL, bỏ qua các file đã xử lý và chỉ tiếp tục chạy phần còn lại, tiết kiệm tối đa thời gian trích xuất.

4.3. Tối ưu hóa tài nguyên mạng bằng Download Archive

- **Vấn đề:** Quá trình thu thập dữ liệu tự động (crawling) từ YouTube dễ bị gián đoạn do kết nối mạng. Nếu chạy lại kịch bản, hệ thống thông thường sẽ tải lại từ đầu toàn bộ dữ liệu, gây lãng phí nghiêm trọng băng thông và dung lượng lưu trữ cục bộ.
- **Giải pháp:** Tích hợp tính năng download_archive để duy trì một tệp nhật ký (ledger) chứa ID của các video đã tải thành công. Trình thu thập dữ liệu sẽ tự động đọc và đối chiếu với danh sách này trước mỗi lượt tải để ra quyết định bỏ qua file cũ.
- **Đánh giá:** Thể hiện tư duy tối ưu hóa tài nguyên phần cứng, đáp ứng chuẩn mực của các hệ thống kỹ thuật dữ liệu (Data Engineering) hiện đại.

studeersnel
messages.pdf_cover_qr_code_label
messages.downloaded_by



studeersnel

messages.pdf_cover_qr_code_label
messages.downloaded_by

Chú thích Hệ thống Tìm kiếm & Truy vấn Âm thanh

1. Khối Đầu vào và Tiền xử lý

- **File âm thanh đầu vào/truy vấn:** Tệp tin audio thô (wav, mp3...) được người dùng tải lên để lưu trữ hoặc dùng làm mẫu tìm kiếm.
- **Tiền xử lý:** Quá trình chuẩn hóa (Resampling), khử nhiễu (Denoising) và phân đoạn âm thanh để đảm bảo dữ liệu "sạch" trước khi trích xuất đặc trưng.
- **Kho lưu trữ file gốc:** Hệ thống lưu trữ vật lý (như Local Storage hoặc Cloud) để người dùng có thể nghe lại file sau khi tìm thấy.

2. Nhánh Xử lý Nội dung (Semantic Branch)

- **Whisper ASR:** Mô hình nhận dạng giọng nói tự động (Automatic Speech Recognition) của OpenAI, chuyển đổi âm thanh thành văn bản.
- **Transcript Text:** Văn bản đầy đủ nội dung từ video/audio, đóng vai trò là dữ liệu nguồn cho tìm kiếm ngữ nghĩa.
- **Sentence-BERT (SBERT):** Mô hình chuyển đổi các câu văn bản thành **Vector nhúng (Embeddings)**, giúp máy tính hiểu được ý nghĩa câu văn thay vì chỉ khớp từng từ.
- **YAKE!:** Công cụ trích xuất từ khóa tự động (Yet Another Keyword Extractor) giúp xác định các chủ đề chính của đoạn âm thanh.

3. Nhánh Xử lý Giọng nói (Biometric Branch)

- **Signal Proc (MFCC & Pitch):** Trích xuất các đặc trưng vật lý của tín hiệu âm thanh như tần số (MFCC) và cao độ (Pitch/F0).
- **ECAPA-TDNN:** Mô hình Deep Learning tiên tiến dùng để tạo ra **Speaker Embedding** (định danh giọng nói), giúp phân biệt người nói này với người nói khác.

4. Khối Lưu trữ và Quản trị dữ liệu

- **Chuẩn hóa Vector L2:** Đưa các vector về cùng một thang đo (không gian đơn vị) để tính toán độ tương đồng (Cosine Similarity) chính xác hơn.
- **FAISS (Facebook AI Similarity Search):** Thư viện chuyên dụng để lưu trữ và tìm kiếm cực nhanh trên hàng triệu vector đặc trưng.
- **MySQL:** Cơ sở dữ liệu quan hệ dùng để lưu trữ thông tin bổ trợ như: tên file, thời gian, từ khóa và bản transcript đầy đủ.

5. Khối Tìm kiếm và Kết quả

studeersnel

messages.pdf_cover_qr_code_label
messages.downloaded_by



- **Module Xử lý & Tìm kiếm:** "Bộ não" của hệ thống, thực hiện so sánh vector của file truy vấn với kho dữ liệu để tìm ra các tệp tin giống nhất.
- **Top 3 kết quả:** Các tệp tin có độ tương đồng cao nhất về mặt nội dung (những gì được nói) hoặc mặt âm sắc (ai là người nói).

Mô tả quy trình thực hiện

1. Giai đoạn Đầu vào & Tiền xử lý

- **Input Audio:** Hệ thống tiếp nhận tệp âm thanh đầu vào
- **Tiền xử lý:** Tệp âm thanh được chuẩn hóa định dạng và khử nhiễu để đảm bảo chất lượng cho các bước trích xuất đặc trưng phía sau.
- **Lưu trữ gốc:** Tệp âm thanh thô được đẩy vào kho lưu trữ để truy xuất lại khi cần hiển thị kết quả.

2. Hai nhánh xử lý song song

Nhánh 1: Xử lý Nội dung

1. **Whisper ASR:** Sử dụng mô hình Whisper để chuyển đổi âm thanh thành văn bản (Speech-to-Text).
2. **Transcript Text:** Kết quả là một văn bản đầy đủ nội dung của video.
3. **Xử lý văn bản:** Từ bản văn bản này, dữ liệu chia làm 2 hướng:
    - **Trích xuất Vector (Sentence-BERT):** Chuyển đổi văn bản thành các vector không gian đại diện cho ý nghĩa nội dung.
    - **Trích xuất Từ khóa (YAKE!):** Tự động tìm ra các từ khóa quan trọng trong đoạn hội thoại.

Nhánh 2: Xử lý Giọng nói

1. **Xử lý tín hiệu:** Trích xuất các thông số kỹ thuật như MFCC (tần số) và Pitch/F0 (cao độ).

studeersnel
messages.pdf_cover_qr_code_label
messages.downloaded_by

2. **ECAPA-TDNN:** Mô hình Deep Learning tạo ra **Speaker Embedding** — một ID duy nhất cho người nói trong tệp âm thanh đó.

3. Giai đoạn Chuẩn hóa & Lưu trữ

- **Chuẩn hóa Vector L2:** Cả vector nội dung (từ SBERT) và vector giọng nói (từ ECAPA) đều được chuẩn hóa về cùng một dạng (L2 Norm) để việc tính toán khoảng cách (độ tương đồng) sau này chính xác hơn.
- **FAISS (Vector Database):** Các vector đã chuẩn hóa được lưu vào FAISS để phục vụ tìm kiếm lân cận cực nhanh.
- **MySQL (Relational Database):** Lưu trữ các thông tin bổ trợ (Metadata), từ khóa (Keywords) và bản văn bản (Transcript) để hỗ trợ tìm kiếm theo từ khóa truyền thống.

4. Giai đoạn Truy vấn & Kết quả

1. Tệp người dùng tải lên đi qua toàn bộ quy trình trích xuất đặc trưng ở trên để tạo ra vector truy vấn.
2. **Module Xử lý & Tìm kiếm:** So sánh vector truy vấn với dữ liệu đã lưu trong **FAISS** (độ tương đồng vector) và **MySQL** (khớp từ khóa).
3. **Kết quả trả về:** Hệ thống đưa ra hai danh sách kết quả riêng biệt:
    - **Top 3 file giống NỘI DUNG nhất:** Các tệp có cùng chủ đề hoặc nội dung nói tương tự.
    - **Top 3 file giống GIỌNG NÓI nhất:** Các tệp có âm sắc, cao độ hoặc cùng một người nói với file truy vấn.

studeersnel
messages.pdf_cover_qr_code_label
messages.downloaded_by